

Discussione di laurea

Utilizzo di modelli linguistici di grandi dimensioni per migliorare il processo di apprendimento per rinforzo.

REPOSITORY

<https://github.com/ttetrao/llm-guided-rl/>

29 SETTEMBRE 2026


PIETRO FAZION

Perché farlo

- Q-learning propaga il valore a ritroso dal goal.
- se il goal si vede di rado, l'agente converge con fatica.
- Idea: generare una funzione di valore utilizzando un LLM su alcuni stati significativi.

Ambiente

- Reward 1 solo sul goal, 0 altrove.
- Il goal è bloccato da una porta.
- Ambiente completamente osservabile.
- Stato grafo: (dx, dy, dir, has_key, door_open)
- Ground truth per il confronto calcolata con value iteration.
- seed usato per proof of concept 1337



Stati usati


Per un singolo seed gli stati totali sono 480,

Di questi ne vengono estratti un sottoinsieme:

- **Bottleneck:** stati in cui lo stage dell'agente cambia.
- **Checkpoint:** stati estratti tra quelli visitati durante il training con q-learning in base a scaglioni di success rate.

Generazione Q -Function



- **Generazione Q-via-V:** il modello llm valuta la mappa ascii dello stato corrente s generando il V-value dei successivi $s' = (s,a)$ seguendo le istruzioni del prompt, e definizioni delle funzioni di valore (**Sutton & Barto**).
- **Output:** un JSON rappresentante la Q-function.
- **Verifica:** lo script scarta le risposte anomale o incoerenti
- **Modelli usati:** Gpt-oss 120b, Gemma4 26b




Risultati

valori stimati

Errore per bucket — DoorKey 1337 - gpt-oss




v_true vs v_llm — DoorKey 1337 - gpt-oss




Accuratezza policy

- **Top-1 tie-aware:** conta come corretta qualsiasi azione a pari merito con l'ottimo.
- **Top-1 strict:** conta come corretta solo la prima azione in ordine.




Inizializzazione

- La Q-Table viene inizializzata usando i valori generati dal LLM
- $\alpha = 0.04$, $\gamma = 0.99$, ϵ -decay = 0.99
- solo bottleneck
- confronto con un agente allenato con iperparametri standard ($\alpha = 0.25$, $\gamma = 0.99$, ϵ -decay 0.998)



Risultati

DoorKey 8x8 seed 1337 | 2000 episodi | llm_results_doorkey_states_8x8_seed1337_gpt-oss_120b.json | LLM-init vs Vanilla (same hp)




Limiti dell'approccio


- generalizzazione è stata testata su un subset di seed, i risultati sono un punto di partenza non una prova definitiva.
- risposte LLM lente e costose
- LLM fatica su ambienti non deterministici come FrozenLake

alpha 0.15, gamma 0.95, eps_decay 0.995 vs alpha 0.15, gamma 0.99, eps_decay 0.999


DoorKey 8x8 seed 13507 | 5000 episodi | llm_results_doorkey_states_8x8_seeds13507-19920-32455-54937-69693_gpt-oss_120b.json | LLM-init vs Vanilla-std



Limiti





MAE = 0.338



Limiti

alpha 0.05, gamma 0.99, eps_decay 0.99 vs alpha 0.1, gamma 0.99, eps_decay 0.998

FrozenLake 8x8 slippery seed 1337 | 3000 episodi | frozenlake_llm_8x8_slippery_q_seed1337_gpt-oss_120b.json | LLM-init vs Vanilla-std



Aspetti esplorabili

- Fine tuning modello locale.
- Valutazione di un numero elevato di stati da seed diversi per provare generalizzazione.
- generazione online di funzione di valore durante il training.

Fine
Grazie per l'attenzione

REPOSITORY

<https://github.com/ttetrao/llm-guided-rl/>

29 SETTEMBRE 2026

PIETRO FAZION