

Discussione di laurea

Utilizzo di modelli linguistici di grandi dimensioni per migliorare il processo di apprendimento per rinforzo.

REPOSITORY

<https://github.com/ttetrao/llm-guided-rl/>

29 SETTEMBRE 2026


PIETRO FAZION

Perché farlo

- Q-learning propaga il valore a ritroso dal goal.
- se il goal si vede di rado, l'agente converge con fatica.
- Idea: generare una funzione di valore utilizzando un LLM su alcuni stati significativi.

Ambiente

- Reward 1 solo sul goal, 0 altrove.
- Il goal è bloccato da una porta.
- Ambiente completamente osservabile.
- Stato grafo: (dx, dy, dir, has_key, door_open)
- Ground truth per il confronto calcolata con value iteration.
- seed usato per proof of concept 1337



Stati usati


Per un singolo seed gli stati totali sono 480,

Di questi ne vengono estratti un sottoinsieme:

- **Bottleneck:** stati in cui lo stage dell'agente cambia.
- **Checkpoint:** stati estratti tra quelli visitati durante il training con q-learning in base a scaglioni di success rate.

Generazione Q-Function



- **Generazione “Q-via-V”:** il modello llm valuta la mappa ascii dello stato corrente s generando il V-value dei successivi $s' = (s,a)$ seguendo le istruzioni del prompt, e definizioni delle funzioni di valore (**Sutton & Barto**).
- **Output:** un JSON rappresentante la Q-function.
- **Verifica:** lo script scarta le risposte anomale o incoerenti
- **Modelli usati:** Gpt-oss 120b, Gemma4 26b




Risultati

valori stimati

Errore per bucket — DoorKey 1337 - gpt-oss




v_true vs v_llm — DoorKey 1337 - gpt-oss




Accuratezza policy

- **Top-1 tie-aware:** conta come corretta qualsiasi azione a pari merito con l'ottimo.
- **Top-1 strict:** conta come corretta solo la prima azione in ordine.




Inizializzazione

- **Stati usati:** solo bottleneck
- La Q-Table viene inizializzata usando i valori generati dal LLM
- $\alpha = 0.04$, $\gamma = 0.99$, ϵ -decay = 0.99
- solo bottleneck
- confronto con un agente allenato con iperparametri standard ($\alpha = 0.25$, $\gamma = 0.99$, ϵ -decay 0.998)



Risultati

DoorKey 8x8 seed 1337 | 2000 episodi | llm_results_doorkey_states_8x8_seed1337_gpt-oss_120b.json | LLM-init vs Vanilla (same hp)







Risultati

Esempio su 5 seed

Non è una prova dell'efficacia sulla **generalizzazione** ma è un punto di partenza.


alpha 0.15, gamma 0.95, eps_decay 0.995 vs alpha 0.15, gamma 0.99, eps_decay 0.999

DoorKey 8x8 seed 13507 | 5000 episodi | llm_results_doorkey_states_8x8_seeds13507-19920-32455-54937-69693_gpt-oss_120b.json | LLM-init vs Vanilla-std



FrozenLake

- **Ambiente non deterministico** il risultato di un'azione è aleatorio (l'agente fallisce 2/3).
- Il modello fatica a gestire la generazione dei valori tenendo conto di quell'aleatorietà e dalla struttura della mappe successive.
- Causa probabile: incapacità di "immaginare" gli stati successivi, modello troppo poco intelligente
- **MAE: 0.17**




Frozenlake

Stati valutati: 19/53 validi (esclusi hole), 36%

Regret medio: quanto valore viene perso scegliendo l'azione che il modello ha valutato migliore invece di quella ottima (value iteration).


- **regret medio:** 0.0114 (0.0043 escluso il caso peggiore)
- **regret medio su 20000 inizializzazioni casuali:** 0.073 (min 0.018, max 0.115)
- **l'inizializzazione** produce comunque un'inizializzazione **migliore** rispetto ad una casuale.



Risultati


alpha 0.05, gamma 0.99, eps_decay 0.99

FrozenLake 8x8 slippery seed 1337 | 5000 episodi | frozenlake_llm_8x8_slippery_q_seed1337_gpt-oss_120b.json | LLM-init vs Vanilla (same hp)



Risultati

alpha 0.05, gamma 0.99, eps_decay 0.99 vs alpha 0.05, gamma 0.99, eps_decay 0.999



Limiti dell'approccio

- generalizzazione è stata testata su un subset di seed, i risultati sono un punto di partenza non una prova definitiva.
- risposte LLM lente e costose
- LLM fatica su ambienti non deterministici come FrozenLake

Aspetti esplorabili

- Fine tuning modello locale.
- Valutazione di un numero elevato di stati da seed diversi per provare generalizzazione.
- generazione online di funzione di valore durante il training.

Fine
Grazie per l'attenzione

REPOSITORY

<https://github.com/ttetrao/llm-guided-rl/>

29 SETTEMBRE 2026

PIETRO FAZION