

Discussione di laurea

Utilizzo di modelli linguistici di grandi dimensioni per migliorare il processo di apprendimento per rinforzo.

REPOSITORY

<https://github.com/ttetrao/llm-guided-rl/>

29 SETTEMBRE 2026


PIETRO FAZION

Perché farlo

- Q-learning propaga il valore a ritroso dal goal.
- Se il goal si vede di rado, l'agente converge con fatica.
- Idea: generare una funzione di valore utilizzando un LLM su alcuni stati significativi.


Reinforcement Learning

- L'agente mappa stati in azioni per **massimizzare** il segnale numerico di **reward**.
- Un **MDP** è una tupla $\langle \mathbf{S}, \mathbf{A}, \mathbf{T}, \mathbf{R}, \gamma \rangle$.
 - **S**: stati.
 - **A**: azioni.
 - $\mathbf{T}(\mathbf{s}' \mid \mathbf{s}, \mathbf{a})$: probabilità di transizione.
 - $\mathbf{R}(\mathbf{s}, \mathbf{a}, \mathbf{s}')$: reward.
 - γ : fattore di sconto.
- La **transizione** ad $\mathbf{s}'$ e la **reward** dipendono unicamente dallo stato e dall'azione correnti.
- **Obiettivo**: trovare una policy $\pi(\mathbf{a} \mid \mathbf{s})$ che massimizzi il ritorno atteso.



DoorKey

- **Stato (S):** (dx, dy, dir, has_key, door_open).
- **Azioni (A):** left, right, forward, pickup, toggle.
- **Modello di transizione (T):** deterministico.
- **Reward (R):** 1 solo sul goal, 0 altrove.
- **Ambiente gerarchico:** il task si puo scomporre in fasi distinte.
- **Ground truth** per il confronto calcolata con **value iteration**.



Stati usati

Per un singolo seed gli stati totali sono 480,

Di questi ne vengono estratti un sottoinsieme:

- **Bottleneck:** stati in cui lo stage dell'agente cambia.
- **Checkpoint:** stati estratti tra quelli visitati durante il training con q-learning in base a scaglioni di success rate.

Generazione Q -Function

- Per ogni stato ho raccolto le **osservazioni** dell'ambiente e le ho trasformate in una **mappa ASCII**.
- **Generazione “Q-via-V”**: il modello LLM valuta la mappa ascii dello stato corrente s generando il V-value dei successivi $s' = (s,a)$ seguendo le istruzioni del **prompt**, e definizioni delle funzioni di valore (**Sutton & Barto**).
- **Verifica**: lo script scarta le risposte anomale o incoerenti
- **Modelli usati**: GPT-OSS 120B, Gemma4 26b


```
+-----+-----+-----+-----+-----+-----+
|      |      |      | ■      |      |      |
+-----+-----+-----+-----+-----+-----+
|      | K  |      | ■      |      |      |
+-----+-----+-----+-----+-----+-----+
|      |      |      | ■      |      |      |
+-----+-----+-----+-----+-----+-----+
|      |      |      | ■      |      |      |
+-----+-----+-----+-----+-----+-----+
|      |      | A(R) | D(O) |      |      |
+-----+-----+-----+-----+-----+-----+
|      |      |      | ■      |      | G  |
+-----+-----+-----+-----+-----+-----+
```

Prompt


- **Formato prompt:** pseudo-XML.
- **4 blocchi statici iniettati dallo script:** <documentation> (MiniGrid), <legend> (simboli ASCII), <v-definition>, <q-definition> .
- **7 mappe ASCII iniettate per stato:** <current_state> che rappresenta s , più <left> <right> <forward> <pickup> <drop> <toggle> rappresentanti $s' = T(s,a)$.
- **Puntualizzazioni** sull'ambiente e **istruzioni** generali.
- Sezioni di **Analisi** e **Analisi Preliminare** per forzare una **chain-of-thought**.
- **Compito:** per ogni azione stimare il valore della v-function ottima.
- **Output richiesto:** JSON corretto.

```
{
  "code": string,
  "preliminary-analysis": string,
  "q-function-values": {
    "left": {
      "analysis": string,
      "value": float
    },
    "right": {
      "analysis": string,
      "value": float
    },
    ...,
    "toggle": {
      "analysis": string,
      "value": float
    }
  }
}
```

Errore per bucket - gpt-oss:120b



Correlazione lineare - gpt-oss:120b




Accuratezza policy

- **Top-1 tie-aware:** conta come corretta qualsiasi azione a pari merito con l'ottimo.
- **Top-1 strict:** conta come corretta solo la prima azione in ordine.

Accuratezza azione - gpt-oss:120b

DoorKey 8x8 seed singolo




Inizializzazione

- **Stati usati:** solo bottleneck
- La Q-Table viene inizializzata usando i valori generati dall'LLM.
- $\alpha = 0.04$, $\gamma = 0.99$, ϵ -decay = 0.99.
- Confronto con un agente allenato con iperparametri standard ($\alpha = 0.25$, $\gamma = 0.99$, ϵ -decay 0.998).


DoorKey 8x8 - gpt-oss:120b

seed singolo - Init vs Std



DoorKey 8x8 - gpt-oss:120b

seed singolo - Init vs no-Init



Risultati

Esempio su 5 seed


Non è una prova dell'efficacia sulla **generalizzazione** ma è un punto di partenza.

Iperparametri usati:

- $\alpha = 0.15$, $\gamma = 0.99$, ϵ -decay = 0.995.
- Confronto con un agente allenato con iperparametri standard ($\alpha = 0.15$, $\gamma = 0.99$, ϵ -decay 0.999).

DoorKey 8x8 - gpt-oss:120b

Init vs Std




FrozenLake (Slippery)

- **Stato (S):** intero $s = r \cdot \text{ncol} + c$ (r = riga, ncol = numero di colonne mappa, c = colonna).
- **Azioni (A):** left, down, right, up.
- **Modello di transizione (T):** T è stocastico (non deterministico), l'azione selezionata viene eseguita con probabilità di $1/3$.
- **Reward (R):** 1 sul goal, 0 altrove
- **Causa probabile:** incapacità di "immaginare" gli stati successivi, modello troppo poco intelligente.
- **MAE: 0.17.**
- **RMSE: 0.203.**

Accuratezza azione - gpt-oss:120b

Frozenlake 8x8 seed singolo




Frozenlake

Stati valutati: 19/53 validi (esclusi hole), cioè 76 coppie (s,a).

Regret medio: quanto valore viene perso scegliendo l'azione che il modello ha valutato migliore invece di quella ottima (value iteration).

- **Regret medio:** 0.0114 (0.0043 escluso il caso peggiore).
- **Regret medio** su 20000 inizializzazioni casuali degli stessi stati: **0.073** (min 0.018, max 0.115).
- **L'inizializzazione** produce comunque un segnale **migliore** rispetto a quella casuale.



Risultati


Esempio su 1 seed

Iperparametri usati:

- $\alpha = 0.05$, $\gamma = 0.99$, ϵ -decay = 0.99.
- Confronto con un agente allenato con iperparametri standard ($\alpha = 0.1$, $\gamma = 0.99$, ϵ -decay 0.998).

FrozenLake 8x8 - gpt-oss:120b





seed singolo - Init vs std



Risultati

FrozenLake 8x8 - gpt-oss:120b

seed singolo - Init vs no-Init



Limiti dell'approccio

- Generalizzazione è stata testata su un subset di seed, i risultati sono un punto di partenza non una prova definitiva.
- Risposte LLM lente e costose.
- LLM fatica su ambienti non deterministici come FrozenLake.

Aspetti esplorabili

- Fine-tuning modello locale.
- Valutazione di un numero elevato di stati con seed diversi per provare generalizzazione.
- Generazione online di funzione di valore durante il training.

Fine
Grazie per l'attenzione

REPOSITORY

<https://github.com/ttetrao/llm-guided-rl/>

29 SETTEMBRE 2026

PIETRO FAZION